1. Рубежный контроль №2

Бурашников Владимир Владимирович, группа ИУ5-22М. Вариант №1.

1.1. Задание

Необходимо решить задачу классификации текстов на основе любого выбранного Вами датасета. Классификация может быть бинарной или многоклассовой. Целевой признак из выбранного Вами датасета может иметь любой физический смысл, примером является задача анализа тональности текста.

Hеобходимо сформировать признаки на основе CountVectorizer или TfidfVectorizer.

В качестве классификаторов необходимо использовать один из классификаторов, не относящихся к наивным Байесовским методам (например, LogisticRegression), а также Multinomial Naive Bayes (MNB), Complement Naive Bayes (CNB), Bernoulli Naive Bayes. Для каждого метода необходимо оценить качество классификации с помощью хотя бы одной метрики качества классификации (например, ассuracy).

Сделайте выводы о том, какой классификатор осуществляет более качественную классификацию на Вашем наборе данных.

1.2. Решение

1.2.1. Загрузка и предобработка данных

```
[22]: | from sklearn.feature_extraction.text import TfidfVectorizer
     import pandas as pd
     #rcv_train = fetch_rcv1(subset='train')
[23]:
     #rcv_test = fetch_rcv1(subset='test')
     df = pd.read_json('./news.json', lines=True)
    df.head()
[24]:
[24]:
                authors
                               category
                                              date
       Melissa Jeltsen
    0
                                  CRIME 2018-05-26
     1
          Andy McDonald ENTERTAINMENT 2018-05-26
     2
             Ron Dicker ENTERTAINMENT 2018-05-26
     3
             Ron Dicker ENTERTAINMENT 2018-05-26
     4
             Ron Dicker
                        ENTERTAINMENT 2018-05-26
                                                  headline
       There Were 2 Mass Shootings In Texas Last Week...
    0
     1
       Will Smith Joins Diplo And Nicky Jam For The 2...
          Hugh Grant Marries For The First Time At Age 57
     2
     3 Jim Carrey Blasts 'Castrato' Adam Schiff And D...
        Julianna Margulies Uses Donald Trump Poop Bags...
                                                       link
    0 https://www.huffingtonpost.com/entry/texas-ama...
     1 https://www.huffingtonpost.com/entry/will-smit...
     2 https://www.huffingtonpost.com/entry/hugh-gran...
```

```
3 https://www.huffingtonpost.com/entry/jim-carre...
     4 https://www.huffingtonpost.com/entry/julianna-...
                                         short_description
     O She left her husband. He killed their children...
     1
                                  Of course it has a song.
     2 The actor and his longtime girlfriend Anna Ebe...
     3 The actor gives Dems an ass-kicking for not fi...
     4 The "Dietland" actress said using the bags is ...
[87]: headline = np.array(df['headline'])
      category = np.array(df['category'])
      # build train and test datasets
      # Train/test splitting for 41 categories of news
      from sklearn.model_selection import train_test_split
      headline_train, headline_test, category_train, category_test =_
       →train_test_split(headline, category, test_size=0.2, random_state=41)
[88]: | from sklearn.feature_extraction.text import CountVectorizer,
      →TfidfVectorizer
      ## Build Bag-Of-Words on train phrases
      cv = CountVectorizer(stop_words='english', max_features=10000)
      cv_train_features = cv.fit_transform(headline_train)
[89]: | # build TFIDF features on train reviews
      tv = TfidfVectorizer(min_df=0.0, max_df=1.0, ngram_range=(1,2),
                           sublinear_tf=True)
      tv_train_features = tv.fit_transform(headline_train)
[91]: |cv_test_features = cv.transform(headline_test)
      tv_test_features = tv.transform(headline_test)
     1.2.2. Обучение моделей
[110]: from sklearn.metrics import accuracy_score
[113]: from sklearn import metrics
      import numpy as np
      def accuracy(classifier,
                              train_features, train_labels,
                              test_features, test_labels):
          classifier.fit(train_features, train_labels)
          print('Accuracy:', metrics.accuracy_score(test_labels, classifier.
       →predict(test_features)))
[114]: from sklearn.linear_model import LogisticRegression
      from sklearn.naive_bayes import MultinomialNB, ComplementNB, BernoulliNB
```

Accuracy: 0.5750665903263549

```
/home/vladimir/PycharmProjects/giis_lab1/env/lib/python3.6/site-packages/sklearn/linear_model/logistic.py:947: ConvergenceWarning: lbfgsu → failed to converge. Increase the number of iterations.

"of iterations.", ConvergenceWarning)
```

Accuracy: 0.5516915187573125

```
[117]: co = ComplementNB()

co_accuracy = accuracy(classifier=co,train_features=cv_train_features,

train_labels=category_train,

test_features=cv_test_features,

test_labels=category_test)
```

Accuracy: 0.5401906848223843

Accuracy: 0.5414104702397252

1.2.3. Вывод

Meтод LogisticRegression, лучше всего решает поставленную задачу многоклассовой классификации. Но значительно больше затрачивает ресурсов и времени.